Introduzione all'IA e all'IA generativa

Come fa una macchina a scrivere come Eco?

AGENDA

1. IA: definizioni generali
2. Classificazione dei sistemi di IA
3. IA generativa: introduzione agli LLM
4. Use case e scenari efficaci

> *«Un problema fondamentale della definizione di "Intelligenza artificiale" è che nessuno sa cosa sia realmente l'intelligenza.»*

Shane Legg, Marcus Hutter, *Universal Intelligence: A Definition of Machine Intelligence*

DEFINIZIONI GENERALI

> *In computer science, artificial intelligence (AI) [...] is intelligence demonstrated by machines, in contrast to the natural intelligence displayed by humans.*

Definizione di Intelligenza Artificiale di Wikipedia fino al 2020

LA PROPOSTA, 31 AGOSTO 1955

«Si cercherà di scoprire come far sì che le macchine usino il linguaggio, formino astrazioni e concetti, risolvano problemi oggi riservati agli esseri umani»

J. McCarthy, M. Minsky, N. Rochester, C. Shannon, *A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence*. Richiesta: due mesi, dieci persone

HANOVER, NEW HAMPSHIRE · ESTATE 1956



John McCarthy

1927-2011

Conia **intelligenza artificiale**, inventa il LISP



Marvin Minsky

1927-2016

Fonda il laboratorio di IA del MIT, consulente per **HAL 9000**



Claude Shannon

1916-2001

Padre della **teoria dell'informazione**



Herbert Simon

1916-2001

Logic Theorist, Nobel per l'economia 1978



Oliver Selfridge

1926-2008

Pandemonium, riconoscimento di forme



John Nash

1928-2015

Equilibrio di Nash, Nobel 1994, *A Beautiful Mind*

E poi Nathaniel Rochester (IBM), Allen Newell, Arthur Samuel, Ray Solomonoff, Warren McCulloch e altri

DEFINIZIONI GENERALI

> *Ai fini presenti, il problema dell'intelligenza artificiale viene considerato come quello di far comportare una macchina in modi che verrebbero definiti intelligenti se fosse un essere umano a comportarsi così.*

John McCarthy, nota alla lista dei partecipanti al *Dartmouth Summer Research Project on Artificial Intelligence*, dopo l'estate 1956

Una lavatrice può essere definita intelligente?

DEFINIZIONI

- La definizione originaria **non ha niente a che fare col pensiero**
- È più legata al **comportamento** (behavior)
- Alan Turing giunse alle stesse conclusioni quando sviluppò il **Test di Turing**

> *«La domanda se un computer possa pensare non è più interessante della domanda se un sottomarino possa nuotare»*

Edsger Dijkstra

DEFINIZIONI

La domanda «Un computer può pensare?» è semplicemente **mal posta**

Keypoints:

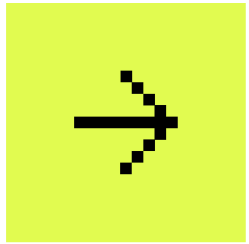
- non fissarsi su analogie fuorvianti
- è più utile studiare **cosa** fa un computer e **come** lo fa

COSA STIAMO MISURANDO?

Due anime nell'Intelligenza Artificiale

Ingegneristica

Aspetto rilevante: eseguire con successo un compito



Cognitiva

COSA STIAMO MISURANDO?



Task Focused AI

oppure IA debole, IA stretta



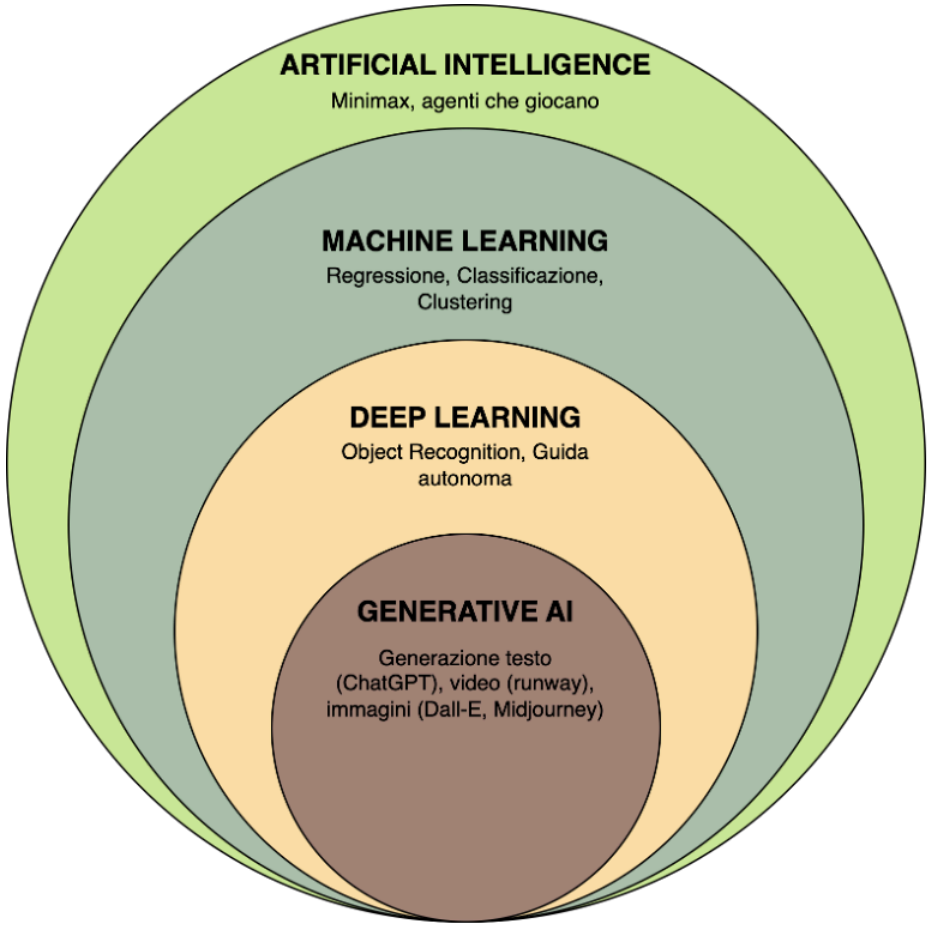
Process Focused AI

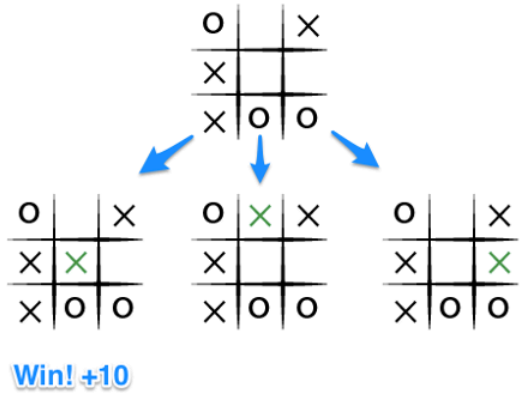
oppure IA cognitiva, IA forte, AGI

PARTE 2

Classificazione dei sistemi di IA

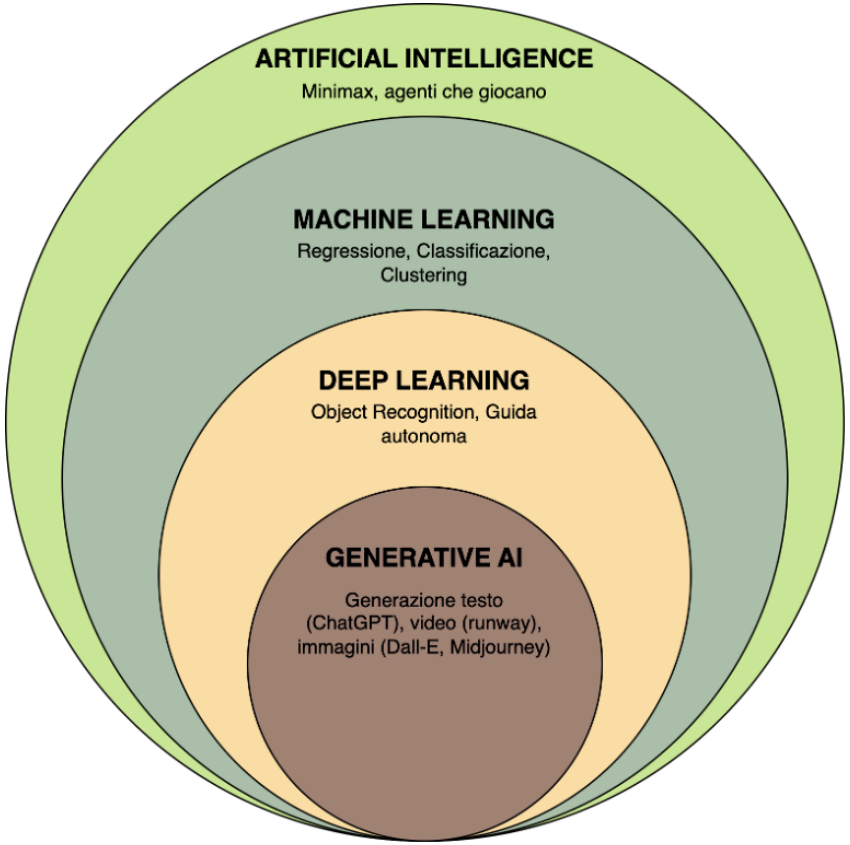
AI SIMBOLICA



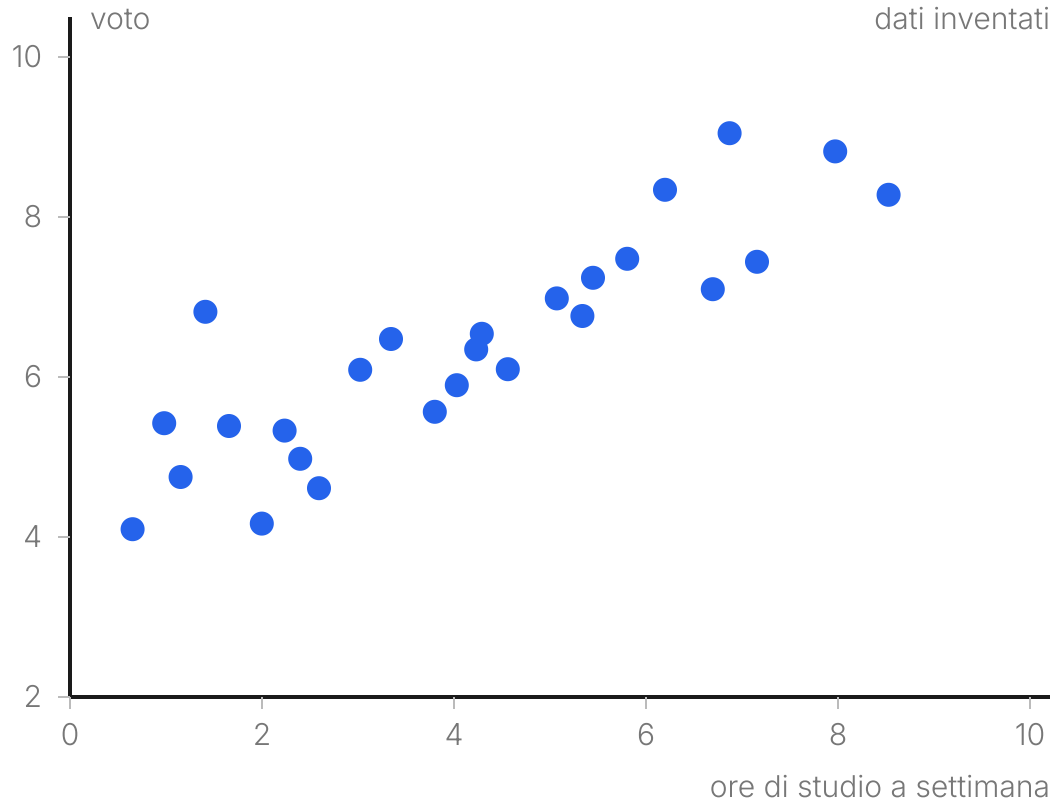


AI SIMBOLICA

- Sistemi che seguono un **set di regole predefinite**
- Logica proposizionale
- Se tutto è regola, tutto è deducibile
- Esempio: un algoritmo che gioca a Tris



$$\text{voto} = \mathbf{a} \cdot \text{ore} + \mathbf{b}$$



Più caratteristiche, più parametri

FEATURE	LABEL
ore di studio	voto
2	5
5	6,5
8	8

$$\text{voto} = a \cdot \text{ore} + b$$

2

parametri

Funziona anche con più caratteristiche: ogni caratteristica avrà il suo parametro. Il numero di parametri aumenta, ma il principio resta lo stesso

MACHINE LEARNING

- Un sistema che fa **predizioni su base statistica**
- Introduzione del concetto di **addestramento**
- La logica lascia spazio alla **probabilità**
- L'algoritmo «impara» osservando le correlazioni senza essere cosciente

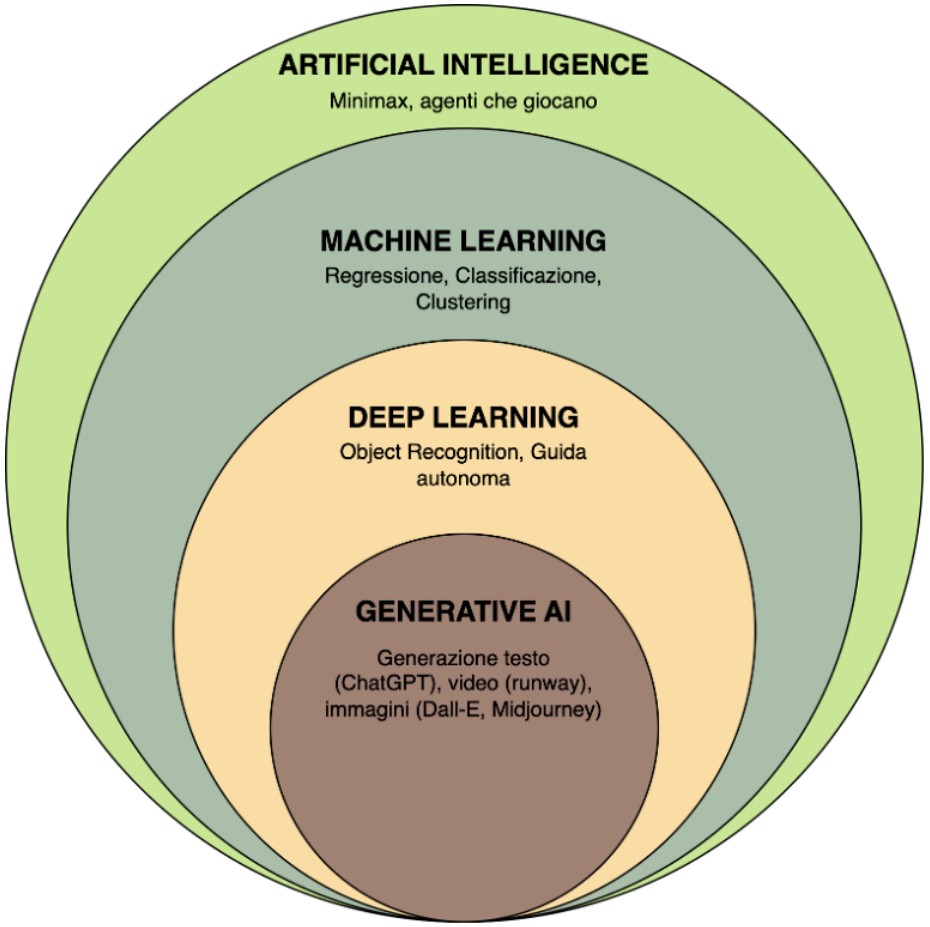
L'importanza dei dati nell'epoca dei big data

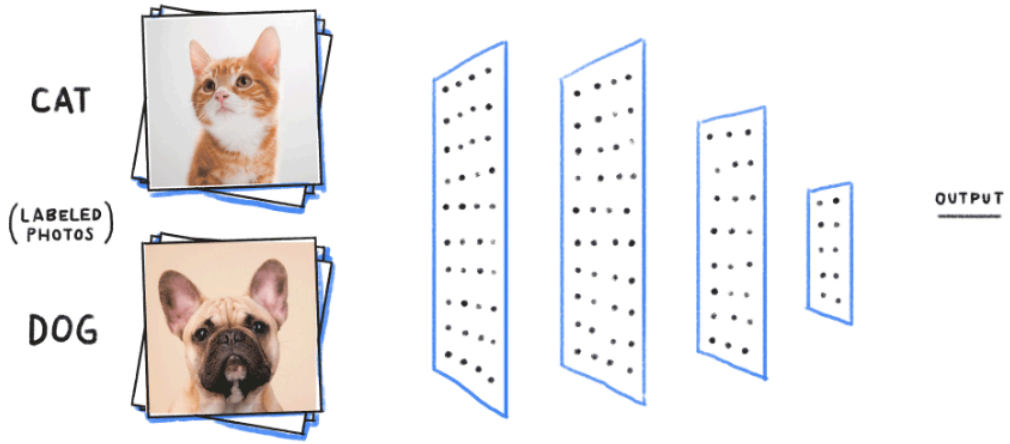
Tutto quello che facciamo è sorgente di dati che sono utilizzati dai provider di servizi per:

- vendita dei dati
  - Ottobre 2026: Spirit Airlines fallisce e Google offre **10 milioni di dollari** per i suoi archivi, circa **100 milioni di email**, per addestrare l'AI. Oltre 120 parlamentari USA protestano: secondo loro i dipendenti non hanno mai autorizzato quell'uso
- addestramento diretto di modelli

Esistono **dataset pubblici** praticamente per qualsiasi cosa

DEEP LEARNING

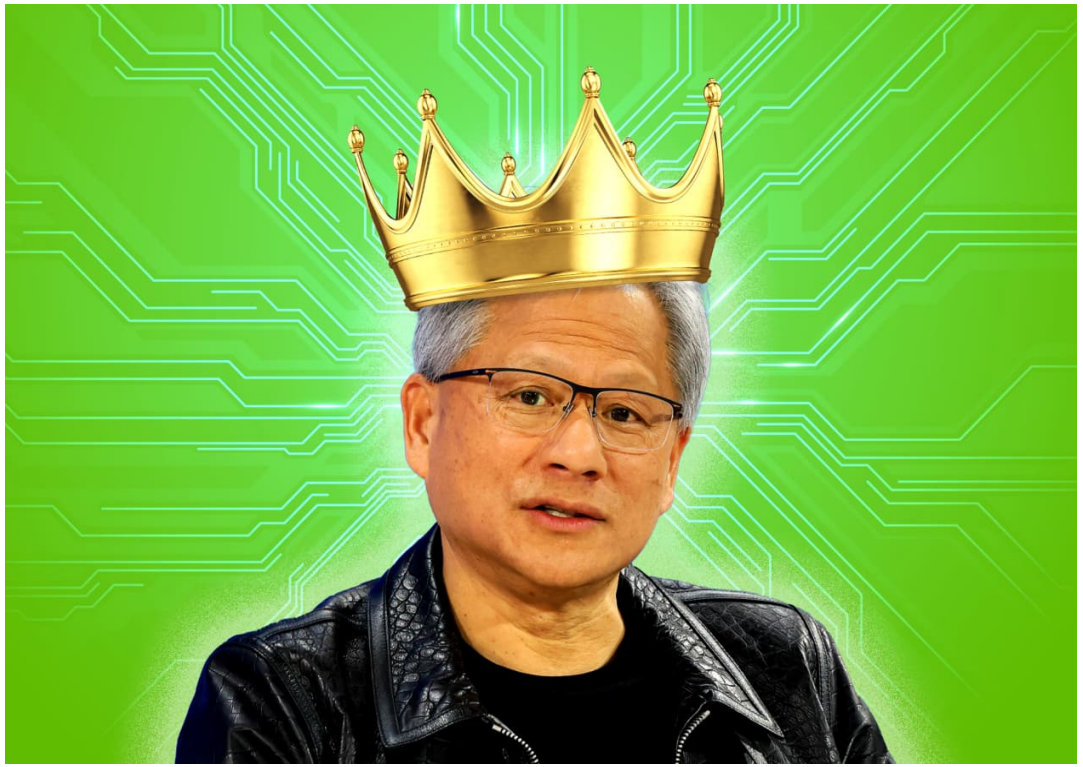




DEEP LEARNING

- Principi identici al machine learning ma con modelli di **reti neurali**
- **Costosi** da addestrare (tempo e denaro)
- **Difficili da spiegare** (bassa explainability)
- **Efficacissimi** in determinati scenari
- Un esempio: la guida autonoma

- Oltre ai dati si creano enormi possibilità per i **produttori di chip**
- Possedere GPU diventa il must have
- Il successo di **nVidia**



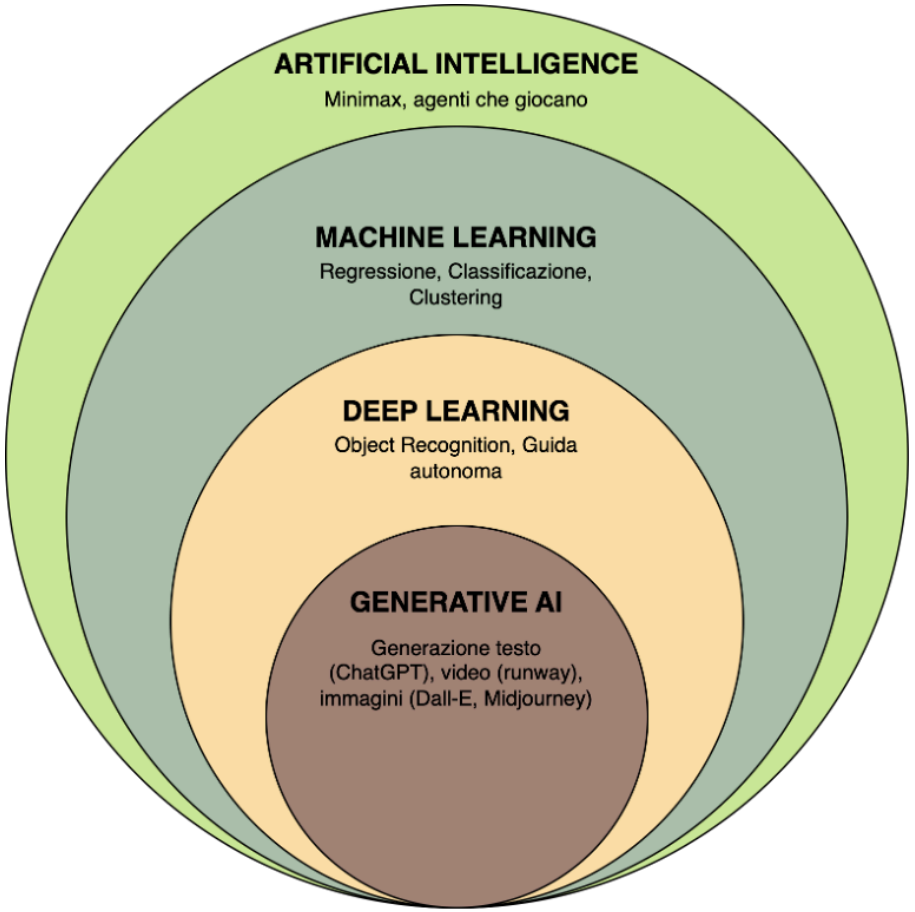
Jensen Huang, CEO di Nvidia

- Oltre ai dati si creano enormi possibilità per i **produttori di chip**
- Possedere GPU diventa il must have
- **AlphaGo – The Movie**



Lee Se-Dol durante il match contro AlphaGo

GENERATIVE AI



Gemini

LLaMA by Meta

runway

GENERATIVE AI

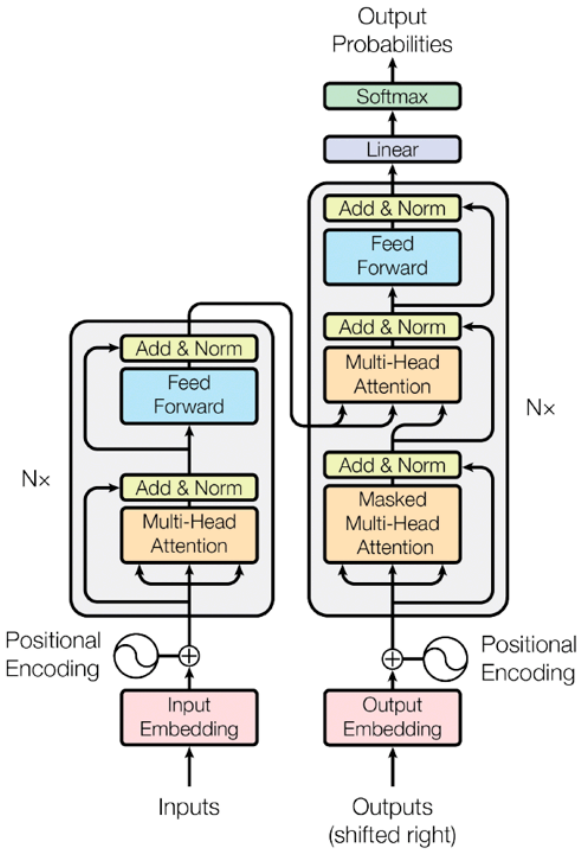
- Dal **2014** le deep neural networks sono utilizzate per creare contenuti «originali» basandosi sui dati di addestramento
- this-person-does-not-exist.com

Ma è dal 2017 che cambia tutto...

...quando Google pubblica il paper **«Attention is all you need»**

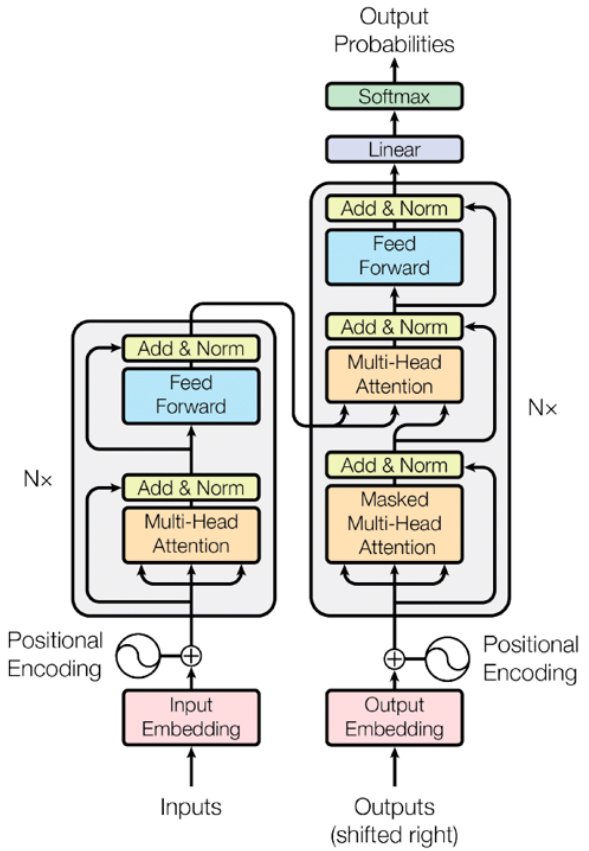
Nel paper si introduce una nuova architettura di reti neurali chiamata **transformer**:

- specializzati nell'elaborazione del linguaggio naturale (NLP)



Schema dell'architettura Transformer

- Originariamente nati per la **traduzione automatica**
- Sono la base degli attuali **Large Language Models**



Schema dell'architettura Transformer

PARTE 3

Large Language Models

RECAP – DA DOVE PARTIAMO

L'IA generativa è un sottoinsieme dell'Intelligenza Artificiale che si concentra sullo sviluppo di sistemi e modelli capaci di **creare contenuti originali** a partire da **dati esistenti**.



RECAP – DA DOVE PARTIAMO

Modelli

Software

Creare contenuti originali

Creare contenuti molto probabilmente inesistenti

A partire da testi esistenti

«Copiando» testi già noti al software (dati di addestramento)

Si tratta di **modelli matematici** in grado di codificare informazioni statistiche su uno o più linguaggi, ossia **quanto è probabile che una parola appaia** in una determinata frase.

```
My favorite color is _____
```

Parola	%
red	32.56%
blue	34.92%
...	...
dog	1.22%

PUNTI CHIAVE

- Il processo di generazione avviene in maniera **sequenziale**
- La generazione avviene su **base statistica**
- Le statistiche sono calcolate in base ai **dati di addestramento**
- I contenuti generati sono scelti da un **vocabolario**

ADDESTRAMENTO

La benzina sono i dati

- Libri, siti, enciclopedie, codice, conversazioni: **miliardi di parole**
- Il modello non memorizza i testi: ne ricava **le regolarità** (quali parole stanno insieme, in quale ordine, in quale contesto)
- Sa solo ciò che c'era nei dati, con **gli stessi squilibri e gli stessi stereotipi**

ADDESTRAMENTO

Quanto è grande la benzina?

15 milioni di siti web

in uno solo dei dataset di addestramento

Apriamo l'inchiesta del Washington Post

Kevin Schaul, Szu Yu Chen, Nitasha Tiku, *Inside the secret list of websites that make AI like ChatGPT sound smart*, The Washington Post, 19 aprile 2023

ADDESTRAMENTO

Un archivio zip che perde i dettagli

Lo zip

Comprime i file e li restituisce identici

Il modello

Comprime miliardi di testi **perdendo dettagli**: quando "decomprime" ricostruisce ciò che è plausibile, non ciò che c'era

Ted Chiang, *ChatGPT Is a Blurry JPEG of the Web*, The New Yorker, 9 febbraio 2023

Il vocabolario del modello

≈ 200.000

pezzi di testo nel vocabolario di GPT-4o. Il modello non conosce altro: ogni testo che legge o scrive è fatto con questi pezzi

GPT-2, nel 2019, ne aveva 50.257

PAROLE INTERE

`·the` `·vita` `·casa` `·scuola` `·docente` `·Bari`

PEZZI DI PAROLA

`mente` `zione` `issime` `ing`

SIMBOLI E CIFRE

`!` `,` `↵` `202`

ALTRE LINGUE ED EMOJI

`ción` `ção` `的` `😀`

E le parole che non ci sono? Si compongono con i pezzi:

docenti → `·doc` `enti` **intelligenza** → `·int` `elligen` `za` **Bitetto** → `·Bit` `etto`

Token reali del tokenizzatore di GPT-4o (o200k_base). Il punto · indica lo spazio, ↵ l'a capo

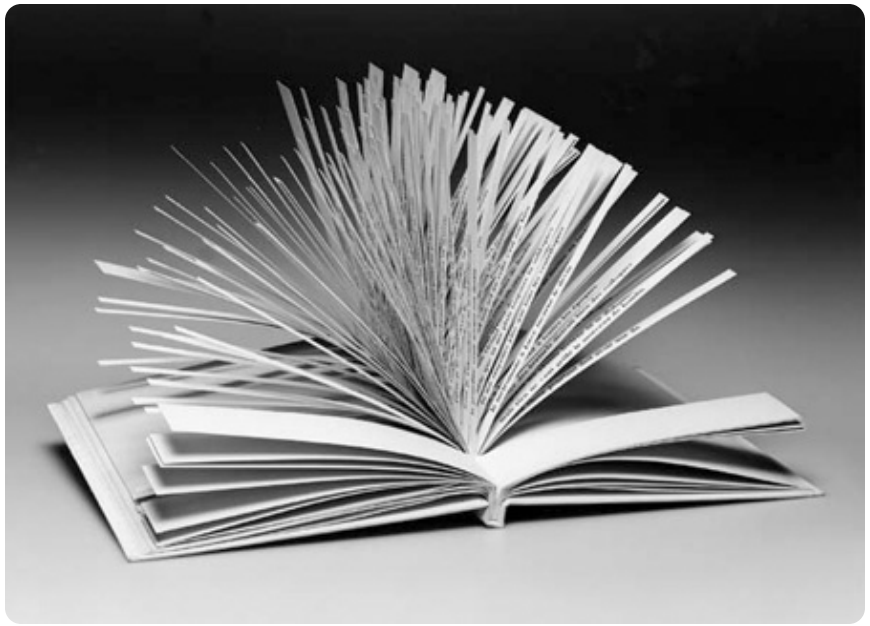
Si parte dall'input dell'utente (**prompt**) e si **tokenizza**

La banca del
fiume è rocciosa

Tokens	Characters
10	29



Raymond Queneau (1903-1976)



Cent mille milliards de poèmes, 1961

- **10 sonetti** di 14 versi, ogni verso su una **striscia** che si sfoglia da sola
- Ogni verso si combina con quelli degli altri sonetti: rima e grammatica tornano sempre
- 10^{14} combinazioni: **centomila miliardi di poesie**. Per leggerle tutte, stima Queneau, circa **200 milioni di anni**

Come i token: pochi pezzi, combinazioni quasi infinite. Ma Queneau costruisce i versi perché ogni combinazione funzioni; il modello sceglie, un pezzo alla volta, in base alla probabilità.

Pezzi di parole

Nel mezzo del cammin di nostra vita	`Nel` `·mezzo` `·del` `·cam` `min` `·di` `·nostra` `·vita`
poeta	`po` `eta`
Il poeta	`Il` `·poeta`
precipitevolissimevolmente	`prec` `ip` `ite` `vol` `issime` `vol` `mente`

Tokenizzatore di GPT-4o (o200k_base). Il punto · indica lo spazio. Ogni modello ha il suo tokenizzatore.

Dai token ai vettori

`Nel` `·mezzo` `·del` `·cam` `min` `·di` `·nostra` `·vita`

1 · UN VETTORE
ogni token diventa una lista di numeri, presa dalla tabella del modello: l'embedding

2 · + LA POSIZIONE
si somma l'informazione sulla posizione: cambiano tutti i numeri. «del» in terza posizione non è uguale a «del» in sesta

3 · UNA TABELLA
8 token × migliaia di numeri: è questo che il modello elabora davvero

Token reali del tokenizzatore di GPT-4o. Valori illustrativi: in un modello vero sono migliaia per token (in GPT-3, 12.288)

Embedding come coordinate



- Palo e Bitetto: coordinate simili, **3,7 km**. Tante cose in comune
- Palo e Parigi: **circa 1.420 km**. Molto meno in comune
- Gli embedding fanno lo stesso con le parole, ma con **migliaia di coordinate** invece di due

È l'ultimo token a spostarsi

La · banca · del · fiume · è



Spazio degli embedding, semplificato in 2 dimensioni. Pesi illustrativi

PARTENZA
il vettore di «è» preso dalla tabella: vicino agli altri verbi

PRIMO STRATO
«è» guarda tutti i token insieme: «banca» e «fiume» pesano di più e lo spingono verso l'acqua

STRATI INTERMEDI
lo stesso meccanismo, strato dopo strato: il vettore si allontana dalla finanza

ULTIMO STRATO
arriva vicino a «ripida», «rocciosa», «piena»

PROIEZIONE
i token più vicini sono i più probabili

Dalla posizione alla parola

La · banca · del · fiume · è

- ·ripida
- ·rocciosa
- ·piena
- ·scivolosa
- ·chiusa
- ·fallita

PROIEZIONE
il vettore di «è» diventa una probabilità per ogni token

TOP-K
restano in gara solo i 4 più probabili

CAMPIONAMENTO
un'estrazione casuale, pesata sulle probabilità: non vince per forza il primo

E SI RICOMINCIA
il token scelto si aggiunge alla frase

LLM – COME GENERANO I CONTENUTI?

Proviamo: un token alla volta

Apri la simulazione

«Il mio colore preferito è...»: probabilità, campionamento, temperatura

Generano contenuti:

- con un processo **iterativo**
- su **base statistica** con una **componente casuale**



I Large Language Models non modellano la conoscenza, ma il linguaggio

LLM – LIMITI INVALICABILI

Knowledge cutoff

Non conoscono fatti avvenuti dopo il loro addestramento



Hallucinations

La loro creatività può ritorcersi loro contro producendo risposte false o errate

Conoscenza di dominio assente

Non sanno rispondere a domande che richiedono informazioni specifiche

Hallucinations: lo dice anche il falso Eco

- Nel falso: **Teofrasto di Melitene**, filosofo bizantino mai esistito, con trattato, manoscritto e segnatura
- Nella realtà: **Tribunale di Firenze, 14 marzo 2025**, un atto cita sentenze della Cassazione inventate da ChatGPT
- Il modello produce ciò che è **plausibile**: la verità non è un criterio del calcolo

> «Si obietterà che una successione plausibile di parole non è pensiero.» Dalla finta Bustina

HANDS ON

> *«L'autolavaggio è a 40 metri da casa. Devo lavare la macchina. Dovrei andarci a piedi o in macchina?»*

MITIGAZIONI

- **Prompt Engineering:** chiedere le cose nel miglior modo possibile
- **Retrieval:** inviare dei file o della conoscenza «esterna» per l'analisi durante la conversazione
- **Fine tuning:** ri-addestrare il modello aggiungendo fra i dati di addestramento altre informazioni (altri testi)

OLTRE GLI LLM – AGENTI AI

Le piattaforme più blasonate di IA generativa possono interagire con moduli terzi per:

- fare ricerche sul web
- analizzare e leggere contenuti da file
- generare grafici anche interattivi

Quando un'applicazione che fa uso di LLM può interagire con altri componenti e **riesce a capire quando farlo** si parla di **agente AI**

PARTE 4

Use case e scenari efficaci

LLM – SONO DA BUTTARE VIA?

- Customer Service di nuova generazione
- Personalizzazione del marketing
- Supporto nell'automazione di processi aziendali
- Revisione di documentazione
- Creazione di corpus di documenti
- Creatività
- Estrazione dati strutturati da documenti non strutturati

…domande?