Prompt Engineering → Context Engineering

Che cosa arriva al modello oltre alla tua frase

Dalla frase al contesto

Prompt engineering

Riguarda la frase scritta in chat

Domanda guida: come formulo la richiesta?

Context engineering

Riguarda tutto ciò che il modello ha a disposizione

Domanda guida: quali istruzioni, dati, esempi e strumenti fornisco?

Tobi Lütke (Shopify), giugno 2025

«The art of providing all the context for the task to be plausibly solvable by the LLM.»

Simon Willison, Context engineering, 27 giugno 2025 · simonwillison.net/2025/Jun/27/context-engineering

Anthropic

«The smallest possible set of high-signal tokens that maximize the likelihood of some desired outcome.»

Effective context engineering for AI agents, 29 settembre 2025 · anthropic.com/engineering/effective-context-engineering-for-ai-agents

Che cosa arriva al modello



La richiesta scritta in chat è uno dei sei pezzi del contesto.

1/6 · Istruzioni

COSA SONO

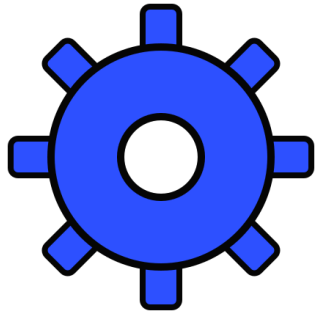
indicazioni valide per tutta la chat, della piattaforma (invisibili) e tue (impostazioni, progetto)

ESEMPIO

"Rispondi in italiano, con un elenco finale di azioni concrete"

ATTENZIONE

si scrivono una volta e agiscono su ogni risposta



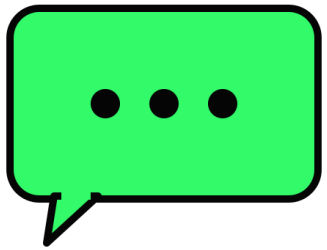
2/6 · Richiesta utente

CHE COS'È

il messaggio che scrivi adesso

ESEMPIO

"Riassumi il listino 2026 in cinque punti per il team vendite"



ATTENZIONE

obiettivo, destinatario, vincoli e formato vanno scritti qui o nelle istruzioni

3/6 · Conversazione

CHE COS'È

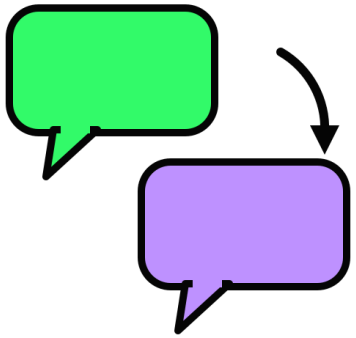
tutti i messaggi precedenti della chat, tuoi e del modello

ESEMPIO

dopo 10 messaggi su un fornitore, una domanda su un secondo fornitore può mescolare i dati

LABAN ET AL. (2025)

un compito spezzato su più messaggi perde in media il 39% di prestazioni



arxiv.org/abs/2505.06120

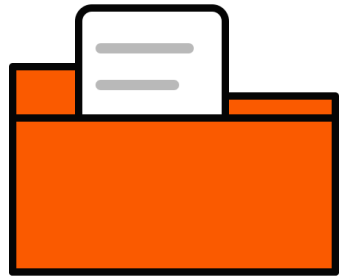
4/6 · Knowledge e file

COSA SONO

PDF, fogli e documenti allegati alla chat o caricati in un progetto

ESEMPIO

il PDF del listino 2026 allegato alla domanda



ATTENZIONE

con molti file il modello legge solo i passaggi recuperati, e un passaggio mancante produce una risposta incompleta

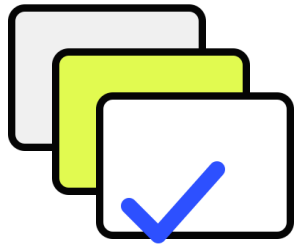
5/6 · Esempi

COSA SONO

casi di input e output che mostrano la risposta attesa

ESEMPIO

"Il sito è completamente offline" → URGENTE



ATTENZIONE

il modello copia anche lunghezza e struttura degli esempi

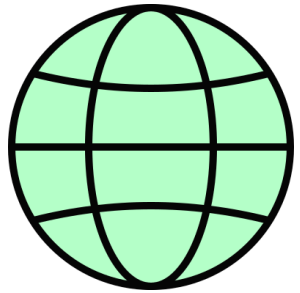
6/6 · Tool e web

COSA SONO

ricerca web, esecuzione di codice, connettori a email, calendario e file

ESEMPIO

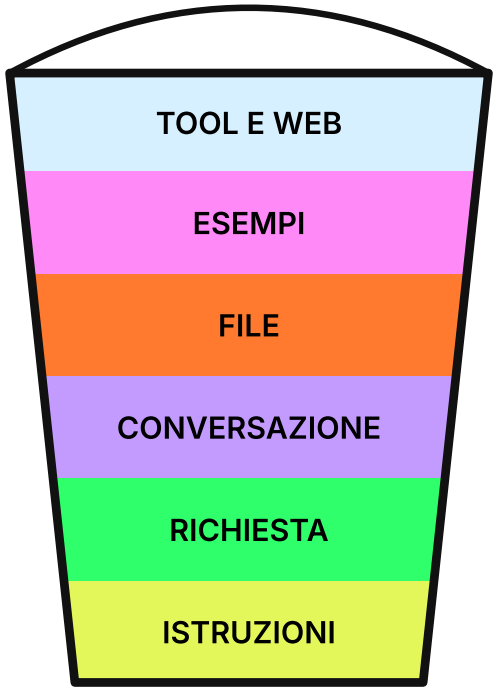
una ricerca web sulle tariffe aggiornate di un fornitore



ATTENZIONE

i risultati entrano nel contesto come testo, e quel testo può contenere istruzioni scritte da altri

Il contesto è un secchio



UN SOLO CONTENITORE

i sei pezzi finiscono nella stessa finestra di contesto

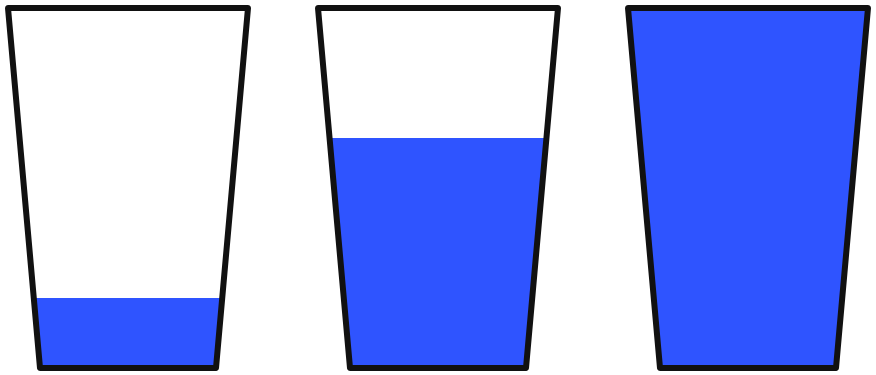
CAPIENZA LIMITATA

si misura in token, cioè pezzi di parola

A OGNI RISPOSTA

il modello rilegge tutto quello che c'è nel secchio

Il secchio si riempie



inizio chat

10 messaggi
e un PDF

chat lunga
e molti file

RESTA TUTTO

ogni messaggio, tuo e del modello, occupa spazio fino alla fine della chat

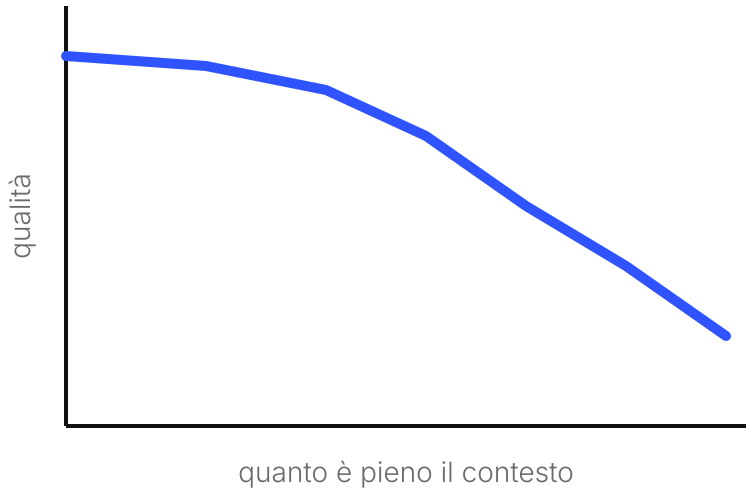
PESI DIVERSI

un PDF di 50 pagine occupa più spazio di decine di messaggi

SECCHIO PIENO

la piattaforma taglia o riassume i messaggi più vecchi

Più è pieno, peggio lavora



CONTEXT ROT

Anthropic (29 settembre 2025): più token nel contesto, meno precisione nel richiamare le informazioni

CHROMA (LUGLIO 2025)

su 18 modelli le prestazioni calano quando l'input si allunga, anche in compiti semplici

LIU ET AL. (2023)

le informazioni a metà di un contesto lungo vengono usate meno di quelle all'inizio e alla fine

Come si svuota il secchio

ARGOMENTO NUOVO

chat nuova

FILE

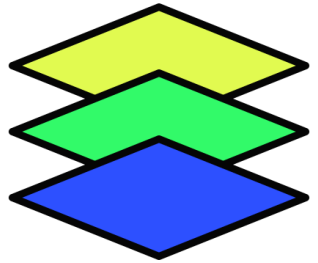
allega solo quelli che servono alla domanda

CHAT LUNGA

chiedi un riassunto dei punti decisi e riparti da lì in una chat nuova

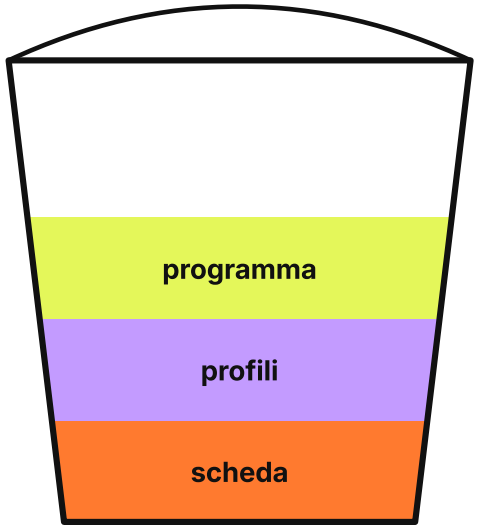
ISTRUZIONI

brevi: occupano spazio in ogni risposta



Tre modi di riempire il secchio

1 · NotebookLM



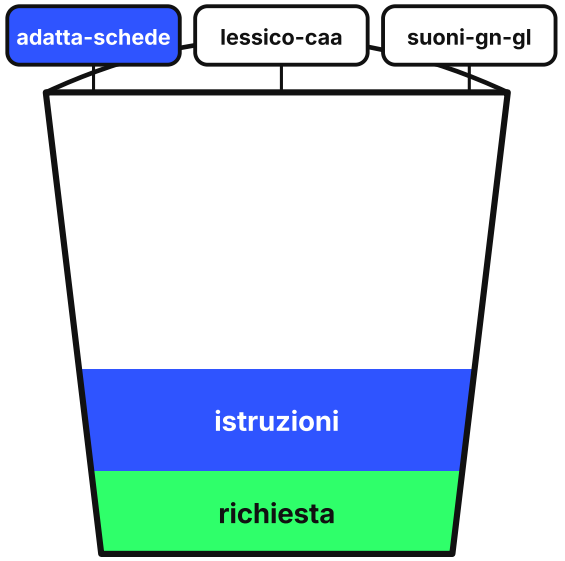
le fonti

2 · Gem



istruzioni sempre dentro

3 · Skill



istruzioni solo quando servono

NotebookLM: le fonti nel secchio

TUTTO FINCHÉ CI STA

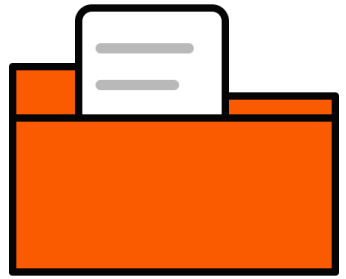
dal 29 ottobre 2025 la chat usa la finestra completa di Gemini, 1 milione di token

LE SPUNTE DECIDONO

una fonte senza spunta non entra nel contesto

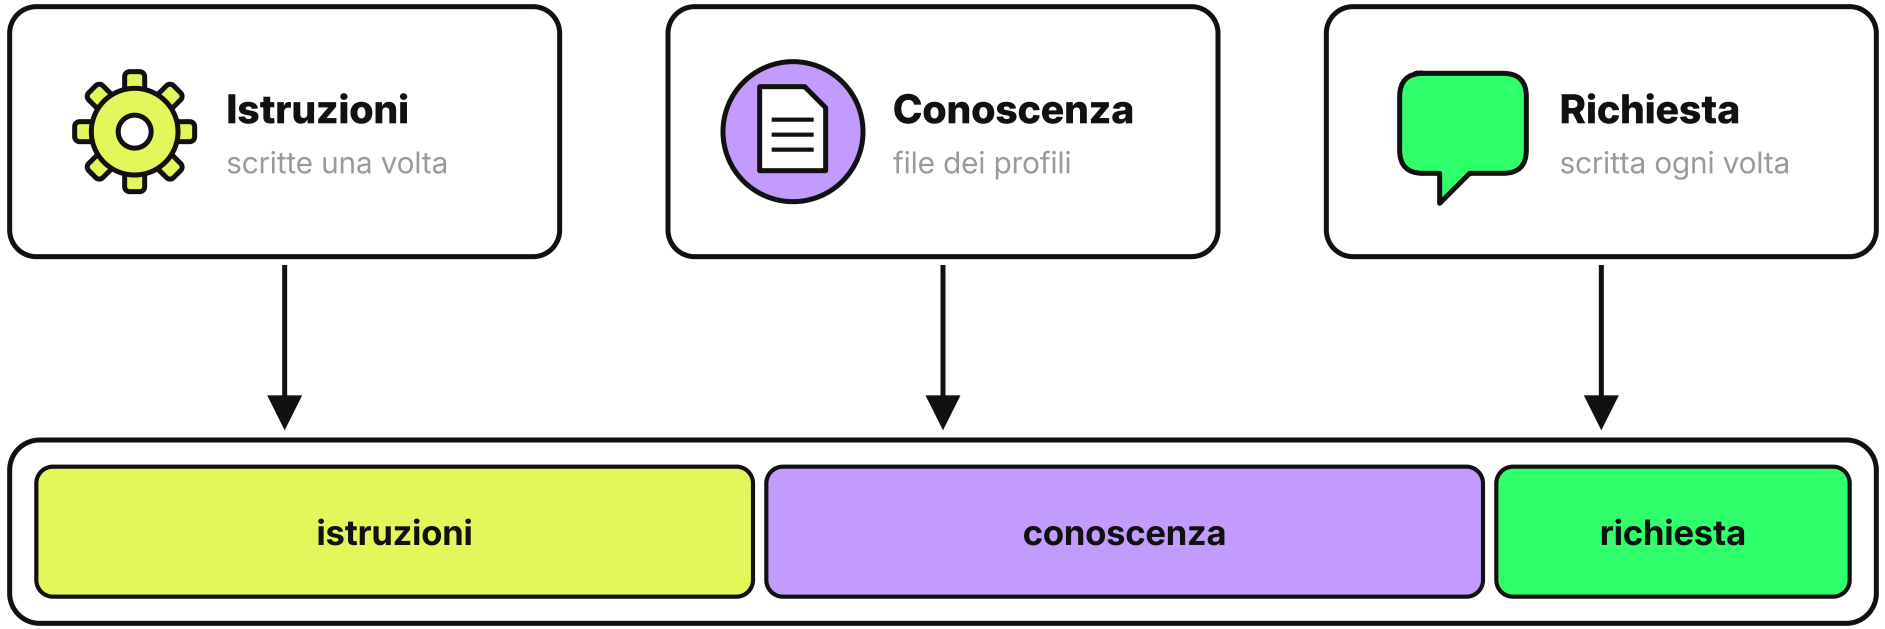
GROUNDING

le risposte citano il passaggio della fonte da cui vengono



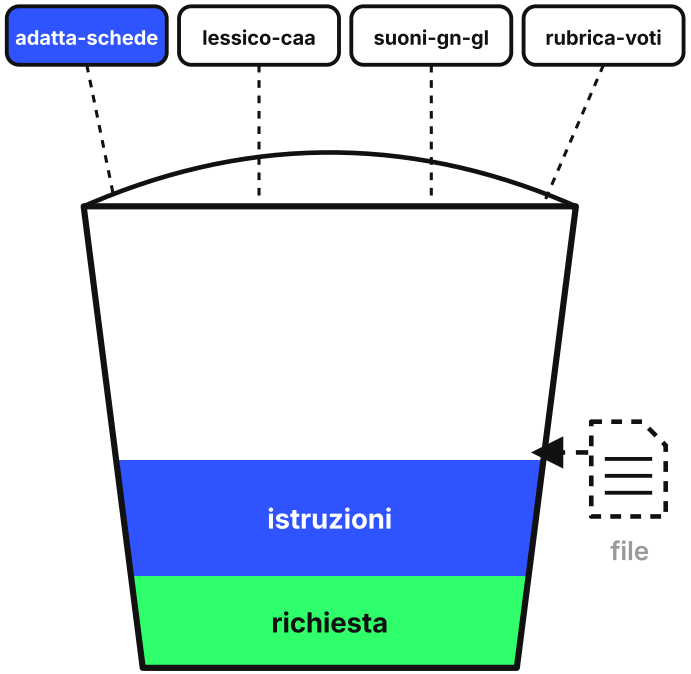
blog.google, Chat in NotebookLM, 29 ottobre 2025

Gem: istruzioni sempre nel secchio



Il contesto a ogni risposta: tutto il Gem entra sempre

Skill: l'etichetta fuori dal secchio



1. **Nome e descrizione**
   sempre, per tutte le skill

2. **Istruzioni complete**
   solo se la skill serve

3. **File allegati**
   solo quando servono

support.google.com/gemini/answer/17102773 · Anthropic, Equipping agents for the real world with Agent Skills, 16 ottobre 2025

Da ricordare

> La qualità dell'output dipende da tutto il contesto che il modello riceve, compresa la frase scritta in chat.

> Il contesto comprende istruzioni, richiesta, conversazione, file, esempi e tool

> Ogni pezzo del contesto si può progettare

